CLIP ViT-B/16 INT8 양자화 · Hailo-10H 이식 — 진행 정리

2026 On-device AI 최적화 챌린지 · 작성 2026-10-17 16:10 KST · 기준 문서: docs/01 인수인계, docs/02 실험기록(E01~E21), docs/PROTOCOL.md · 작성 Claude (팀 검토용)

> **한 줄 요약.** 정적 INT8 손실의 원인을 **블록 5~7 fc2 입력의 소수 이상치 채널**로 특정했고, 그 채널만 격리하는 같은 전략을 PC(ONNX Runtime)와 NPU(Hailo-10H)에 적용했다. 10/17 15:22 최종 구성을 동결했고(ORT **SPL-b567-k32**, Hailo **H-splf-b7-k32**), 봉인했던 COCO-confirm·CIFAR test 최종 판정을 진행 중이다. ORT 판정은 끝났고 Hailo는 19시 전후 완료 예정.

2.28배	**−55%**	**−74%**	**−0.95%p**	**+0.65%p**
ORT 속도 (p50 58.06 → 25.51 ms)	실행 메모리 (516 → 232 MB)	모델 크기 (344.9 → 89.8 MB)	COCO-confirm R@1 (41.79 → 40.84)	CIFAR-100 test top-1 (68.01 → 68.66)

목차

1. 프로젝트 개요와 심사 기준
2. 실행 환경과 작업 방식
3. 평가 설계 (데이터·지표·마진·선택 규칙)
4. 실험 흐름 한눈에 보기 (E01~E21)
5. 핵심 발견: 손실의 원인
6. ORT(PC) 결과
7. Hailo-10H 결과
8. 추가 경량화 축: 입력 해상도 축소
9. 실패·중단한 시도
10. 최종 구성과 최종 판정 (진행 중)
11. 남은 일과 일정
12. 보고서 작성 시 유의점

부록. 구성 이름 읽는 법 · 주요 파일

1. 프로젝트 개요와 심사 기준

- **주제:** Edge NPU 이식을 전제로 한 CLIP ViT 이미지 인코더의 INT8 양자화 구성 탐색과 그 전략의 Hailo 이식
- **모델:** CLIP ViT-B/16 이미지 인코더 (open_clip `ViT-B-16`, openai 가중치, QuickGELU). ONNX opset 17, 입력 [1,3,224,224], 출력 512차원. 텍스트 인코더는 FP32 고정(양자화·측정 대상 아님)
- **대상 장치:** PC CPU(ONNX Runtime) + Hailo-10H NPU (Hailo DFC 5.4.0으로 HEF 컴파일, 정적 양자화·고정 그래프만 지원)
- **마감:** 보고서 11/1 23:59

단계	심사 항목 (배점)	우리 쪽 근거
예선	보고서·실험설계 35 / 최적화 기법 적절성 25 / 성능 개선도 25 (속도·메모리·크기, PC CPU FP32 대비) / 정확도 유지 15	봉인 평가셋·사전 규칙·bootstrap CI(설계), 원인 기반 이상치 격리(기법), 2.28배·−55%·−74%(개선도), confirm −0.95%p(정확도)
본선	실기기 30 / 실측 성능 30 / 정확도 20 / 발표 20	Hailo-10H HEF 확보(컨텍스트 13). 보드 실측은 아직 없음

2. 실행 환경과 작업 방식

- PC00: i9-14900KF (AVX2·AVX-VNNI), WSL Ubuntu 22.04, RAM 23.5 GB. DFC도 GPU 없이 CPU로 동작
- 파이썬 환경 2개를 섞지 않음: 파일럿 `~/venvs/halio` (torch 2.14.1+cpu, ORT 1.23.2, open_clip 3.3.0) / DFC `~/venvs/hailo` (DFC 5.4.0, TF 2.19.1)
- 큰 파일(데이터·모델·HAR·HEF)은 `D:\halio_data`, 코드·문서·결과는 프로젝트 폴더
- **작업 대기소:** `00_작업대기소_켜기.bat`을 켜 두면 `jobs/*.sh`를 이름 순서로 하나씩 WSL에서 실행. 로그 `jobs/logs/`, 끝난 스크립트 `jobs/done/` (삭제 금지 = 무엇을 돌렸는지의 기록)
- 폴더 정리(10/14): 실행 bat은 `실행파일_bat/`, 설치 파일은 `installers/`, 백업은 `_archive/`, 문서는 `docs/` 00~05 번호 순

3. 평가 설계

3-1. 데이터 분할 (모두 첫 평가 전에 고정, sha256·겹침 0 기록)

용도	세트	크기	비고
캘리브레이션	COCO val2017 무작위 64장 × 3묶음 (s0/s1/s2), CIFAR 64장 × 3묶음(비교용)	64	합집합 189장은 평가에서 제외 (`coco_ret_exclude.txt`)
설정 선택 (주)	COCO-select 텍스트→이미지 검색	2,405장 / 캡션 12,035	seed 2026 분할. 10/13부터 주 평가
설정 선택 (보조)	CIFAR-100 검증 (train에서 클래스당 100장)	10,000	표준오차 ±0.46%p
최종 판정 (봉인)	COCO-confirm	2,406장 / 캡션 12,033	`--i-know-final` 없이는 열리지 않음. 10/17 처음 개봉
최종 판정 (봉인)	CIFAR-100 test	10,000	보조 지표, 같은 시점에 1회

3-2. 지표

- **R@K (Recall@K):** 캡션으로 검색했을 때 정답 사진이 상위 K장 안에 들어온 비율. 이미지별 성적(캡션 hit@K 평균)의 평균. R@1을 판정에, R@5·R@10은 보고 항목으로 사용
- **95% 신뢰구간:** 이미지 단위 짝지은 bootstrap 2,000회 (모든 구성에 같은 재표집 적용)
- **CIFAR:** zero-shot top-1 ("a photo of a {}"), McNemar 정확 검정으로 짝지은 비교
- **속도:** CPU 4스레드, 배치 1, 별도 프로세스, 워밍업 20 + 300회 × 3반복(순서 무작위), p50·p95. 메모리 VmHWM(최대 상주 메모리). MLPerf Inference 규칙 준용
- **Hailo 속도:** 예선에서는 DFC 프로파일러의 컨텍스트 수·추정 fps (**실측 아님**), 본선에서 보드 실측

3-3. 비열등 마진과 선택 규칙 (PROTOCOL.md)

날짜	내용
10/14 팀 확정	**마진 2%p:** R@1 차이(같은 플랫폼 FP32 대비)의 CI 하한 ≥ −2.0%p면 "FP32와 거의 같다". 근거: 갤러리 2,400장에서 R@1 CI 반폭이 약 ±1.4%p라 1%p는 판별력 부족 **선택 순서:** ① 마진 통과 → ② 그중 빠른 것 → ③ 동률이면 R@1. 플랫폼별 1개
10/16 보완	1. 최종 후보는 입력 224 양자화 구성에서만(해상도 축소는 별도 축) 2. 지연 차 5% 이내면 메모리 → 크기 순 3. 마진 통과 후보 전체 표 보고 4. Hailo도 같은 규칙(예선은 컨텍스트 수)
10/17 추가	5. **NPU 실행 가능 조건:** ORT 최종 후보도 Hailo에서 실행 가능한 **정적** 구성만. 동적(A1 계열)은 비교 기준
10/17 15:22	**구성 동결:** ORT SPL-b567-k32, Hailo H-splf-b7-k32. 결과가 나빠도 바꾸지 않음

> **투명성 메모.** 마진(10/14)과 보완(10/16·10/17)은 COCO-select 결과와 10/17 속도 측정을 본 뒤에 정했다. 특히 5번 조건으로 ORT 1순위가 A1-c67-pc(동적) → SPL-b567-k32로 바뀌었다. 이 때문에 최종 판정은 한 번도 보지 않은 COCO-confirm 1회로 한다. 보고서에 이 순서를 그대로 밝힌다.

4. 실험 흐름 한눈에 보기

① 기준선	② 원인 탐색	③ 원인 확인	④ 해결	⑤ 이식	⑥ 판정
A0 FP32, A1 동적, A2 정적 → A2 붕괴	탐침·캘리브 무효 → 민감도로 fc2 b5~7 특정	활성값: 3~4개 채널에 이상치	fc2 보호(혼합정밀도) → 이상치 채널만 분리(SPL)	Hailo: 16비트 보호 → 채널 격리로 비용 제거	속도 측정 → 동결 → confirm·test

ID	날짜	실험	결과 요약
E01	10/5	PyTorch ↔ ONNX 일치 (P1 게이트)	최대 오차 1.03e-5, 최소 코사인 0.99999988 → 통과
E02	10/5	첫 비교표 A0·A1·A2	A0 68.80 / A1 65.02 / **A2 2.09% 붕괴**
E03	10/5	A2 회복 탐침 7종 + 캘리브 A/B 5종	전부 1.5~4.8% → 범위 추정 방식 문제가 아님
E04	10/6	A2m: 정적 대상을 가중치 MatMul 49개로 제한	53.55% (아직 −15%p)
E05	10/6	레이어 민감도 1~3단계	fc2 12개 FP32 → 회복 100%. 블록별 b7 75% / b6 49% / b5 15%
E06	10/6	혼합정밀도 후보 속도	A1보다 정확하지만 약 20% 느림 (정적 QDQ 오버헤드)
E07	10/6~7	Hailo: fc2 16비트(a16_w16)	공식 63.65 → fc2b67 69.55 (2,000장). 컨텍스트 13 → 15
E08	10/7	활성값 분포	fc2 b7 absmax 42, 99.9%가 쓰는 눈금 9칸/255. 민감도 순서와 일치
E09	10/7	캘리브 A/B 재실험 (A2m 기준)	fc2 처리 후에는 캘리브 차이 0.6%p 이내로 견고
E10	10/7	Hailo 5,000장 평가	FP 68.68 / 공식 62.66 / fc2b67 68.34 (McNemar p=1.1e-30)
E11	10/13	per-channel · QOperator · INT4	S-c67-pc 69.09%. QOperator 이득 없음, INT4 기각
E12	10/13	이상치 채널 분리(SPL) · 동적+fc2 보호	**SPL-b567-k32 69.47%**, A1-c67-pc 68.68% (동적에도 통함)
E13	10/13	평가 축 변경: COCO 검색	HF 공식 모델과 코사인 1.000000, 분할 고정
E14	10/13~14	COCO-select 검색 결과	CIFAR 캘리브의 이득은 도메인 효과였음 (H-cifar 23.68)
E15	10/13	DFC 프로파일러	컨텍스트 13/14/15 → 추정 221/170/140 fps
E16	10/14	마진 2%p · 선택 규칙 (팀)	통과: ORT 3개, Hailo 2개
E17	10/14~15	텍스트 인코더 HEF (부가)	parse 성공, finetune이 CPU에서 WSL 정지 → 중단
E19	10/15~17	입력 해상도 축소 192/176/160	R192 양자화 포함 −1.14 경계 통과, 18.25 ms (별도 축)
E18·19	10/17	ORT 후보 속도 측정	SPL-b567-k32 25.51 / S-c67-pc 26.29 / A1-c67-pc 24.05 ms
E20	10/16	대리 지표: 보호할 층을 캘리브 1회로 고르기	bulk_levels < 20 = 정확히 fc2 b5·6·7 (데이터 3종 모두)
E21	10/16	Hailo 이상치 채널 격리 1~3차	**H-splf-b7-k32**: −1.10 마진 통과, 컨텍스트 13, 추정 218 fps
E22	10/17	최종 판정 (confirm + test)	ORT 완료, Hailo 진행 중

5. 핵심 발견: 손실의 원인

5-1. 레이어 민감도 (CIFAR 검증, A2m 53.55%에서 한 층씩 FP32로 되돌림)

되돌린 층	top-1	회복률	되돌린 층	top-1	회복률
fc2 12개 전체	68.85%	100%	fc2 블록 7	64.94%	75%
fc1 12개	55.28%	11%	fc2 블록 6	61.08%	49%
qkv / out / proj	≈ 변화 없음	0~5%	fc2 블록 5	55.78%	15%
조합: b6·7 67.38 / b5·6·7 68.25 / b4~7 68.41			나머지 fc2 블록	—	≤ 7%

5-2. 왜 그 층인가: 활성값 분포 (E08, 사실)

- fc2 입력의 절댓값 최댓값: b5 17, b6 26, **b7 42**. 이 큰 값이 **3,072채널 중 3~4개 채널에 몰려 있음**
- 8비트 눈금(255칸)을 최댓값에 맞추면 나머지 99.9% 값은 b7에서 **9칸**만 사용 (다른 fc2는 43~71칸) → 대부분의 값이 거칠게 반올림됨
- 민감도 순서(b7 > b6 > b5)와 이상치 크기 순서가 일치 → "이상치 때문에 눈금이 낭비된다"는 가설이 측정으로 확인됨
- COCO-select 사진에서도 같은 모양(E14) → 데이터가 아니라 **모델 고유 특성**

5-3. 캘리브레이션 1회로 보호할 층 고르기 (E20, 사실 + 일반화는 가설)

- 지표 bulk_levels = 입력 활성값 99.9%가 8비트 255칸 중 몇 칸을 쓰는가
- 49개 행렬곱 중 **bulk_levels < 20인 층 = 정확히 fc2 블록 5·6·7** = 민감도 실험 상위 3개. 캘리브 데이터 3종 모두 같음
- 층 종류 순위도 완전 일치: fc2(8.9) < fc1(25.5) < qkv(38.4) < out(41.2) < proj(72.6)
- 의미: 수십 번의 민감도 평가 없이 **캘리브레이션 1회**로 보호 대상을 고를 수 있음. 다른 모델에서의 검증은 아직 없음

6. ORT(PC) 결과

6-1. 정확도 (COCO-select R@1, A0 = 40.87% 기준)

구성	방식	R@1	차이 [95% CI]	마진	CIFAR 검증
A0	FP32	40.87	—	—	68.80
A1	동적 INT8	39.32	−1.56 [−2.29, −0.84]	미통과	65.02
A2	정적 INT8 기본	0.15	붕괴	미통과	2.09
A2m	정적, MatMul 49개만	34.06	−6.81	미통과	53.55
S-c67-fc2	A2m + fc2 b6·7 FP32	39.32	−1.55 [−2.26, −0.81]	미통과	67.38
S-c67-pc	위 + per-channel	40.12	−0.75 [−1.41, −0.12]	통과	69.09
SPL-b567-k32	**정적 + b5~7 이상치 32채널만 FP32**	**40.09**	**−0.78 [−1.38, −0.21]**	**통과**	**69.47**
A1-c67-pc	동적 + fc2 b6·7 FP32 + pc	40.55	−0.32 [−0.79, +0.15]	통과 (비교 기준)	68.68

6-2. 속도·메모리·크기 (10/17 08:24, 같은 세션, 시작 부하 0.01)

구성	p50 ms	p95 ms	FP32 대비	메모리 MB	크기 MB	비고
A0 FP32	58.06	60.02	1.00배	516	344.9	기준
A1 동적	22.26	23.17	2.61배	198	89.0	마진 미달
A1-c67-pc (동적)	24.05	24.83	2.41배	204	103.6	NPU 불가 → 비교 기준
SPL-b567-k32	**25.51**	**26.51**	**2.28배**	**232**	**89.8**	**ORT 최종**
S-c67-pc	26.29	27.40	2.21배	244	103.7	지연 차 3.1% → 메모리·크기에서 밀림

- 정수 연산 비율: SPL-b567-k32 63.6%, 정수 커널 시간 56.3%. patch embedding Conv는 FP32 (ORT 1.23.2 ConvInteger 커널 미지원, PROTOCOL 5.1)
- 선택 과정: 정적 후보 중 마진 통과 2개 → 지연 차 5% 이내 → 메모리(232 < 244)·크기(89.8 < 103.7)로 SPL-b567-k32
- 주의: 3반복 중 SPL-b567-k32 한 번 p95 38.5 ms로 튐(나머지 26~27)

7. Hailo-10H 결과 (DFC 5.4.0 에뮬레이터, 컨텍스트·fps는 프로파일러 추정)

7-1. 1단계: fc2 층 전체를 16비트로 (E07·E10·E14)

구성	COCO R@1 차이 [CI]	CIFAR 5,000장	컨텍스트	추정 fps	HEF
H-FP (양자화 전)	40.87 (기준)	68.68	—	—	—
H-official (공식 설정)	−2.95 [−3.86, −2.07]	62.66	13	221	79.3 MB
H-fc2b7	−0.48 [−1.28, +0.30]	—	14	170	—
H-fc2b67	−0.80 [−1.53, −0.04]	68.34	15	140	84.8 MB

ORT에서 찾은 원인과 해결이 Hailo에서도 그대로 통했다. 다만 16비트 층이 컨텍스트를 늘려 **추정 속도가 23~37% 떨어지는 비용**이 생겼다.

7-2. 2단계: 이상치 채널 격리 (E21, 10/16)

비용을 없애려고 16비트로 계산할 부분을 이상치 32채널로 줄였다. ① 캘리브 64장으로 fc2 입력 채널별 최댓값을 재서 상위 32개를 고르고 ② fc1 출력 순서를 바꿔 그 채널을 맨 뒤로 모은 뒤(수학적으로 같은 모델, 코사인 ≥ 0.9999998) ③ 연속 구간으로 잘라 큰 8비트 층 + 작은 16비트 층으로 나눴다. 고정 그래프만 받는 Hailo 컴파일러도 그대로 받아들였다.

차수	구성	R@1 차이 [CI]	컨텍스트	추정 fps	마진	알게 된 것
1차	H-spl-b7-k32 (fc2만 분할)	−1.43 [−2.20]	13	218	미통과	16비트 비용은 사라졌지만 정확도가 −1.3~−1.6에서 멈춤. 보호 블록 수를 늘려도 그대로 → 보호 범위 문제가 아님
1차	H-spl-b67-k32	−1.27 [−2.02]	13	218	미통과	
2차	H-spl-b567-k32	−1.56 [−2.35]	13	218	미통과	
2차	H-spl-b7-k64	컴파일 실패	—	—	—	컴파일러 내부 오류 (BackendAllocatorException)
3차	**H-splf-b7-k32 (fc1+GELU+fc2 분할)**	**−1.10 [−1.89, −0.28]**	**13**	**218**	**통과**	**컴파일된 그래프를 보니 fc1+GELU 출력 3,072채널이 한 텐서로 8비트가 된 뒤 나뉘고 있었음 → fc1부터 두 갈래로 나눠 이상치 채널이 끝까지 16비트로 가게 함**
3차	H-splf-b67-k32	−1.25 [−2.00]	13	218	경계	

> **해석 (사실과 가설 구분).** 사실: 이상치 채널 격리로 컨텍스트가 공식과 같은 13개로 돌아왔고, 추정 fps는 공식 대비 −1%, 공식 대비 R@1 손실은 −2.95 → −1.10으로 줄었다. 가설: 1·2차 → 3차 개선(+0.33%p)은 신뢰구간이 겹쳐 통계적으로 확실하지 않다. 층 전체 16비트(−0.48)와의 남은 차이 0.6%p의 원인 후보는 32채널 밖 채널, 16비트 층 뒤 Add가 8비트, 캘리브 seed 변동(미측정)이다.

8. 추가 경량화 축: 입력 해상도 축소 (E19)

양자화와 다른 축. 학습 없이 위치 임베딩을 bicubic 보간(open_clip `resize_pos_embed`와 같은 방식)해 입력을 줄였다. 토큰 수가 줄어 모든 층의 계산이 줄어든다. 선택 규칙 1번에 따라 최종 후보가 아니라 "추가 속도 선택지"로 보고한다.

크기 (토큰)	FP32 R@1 차이	A1-c67-pc R@1 차이	FP32 p50	A1-c67-pc p50
224 (197)	기준	−0.32 통과	58.06 ms	24.05 ms
192 (145)	−0.72 [−1.49] 통과	−1.14 [−1.95] 경계 통과	46.03 ms	18.25 ms
176 (122)	−1.06 [−1.90] 통과	−1.50 [−2.39] 미통과	38.33 ms	15.66 ms
160 (101)	−3.06 미통과	−3.29 미통과	32.09 ms	13.26 ms

- 해상도 손실과 양자화 손실은 거의 더해진다 (192: −0.72 + 약 −0.4 ≈ −1.14)
- CIFAR는 32px 원본을 키운 것이라 해상도에 둔감 → 해상도 판단에는 COCO만 의미 있음
- R192 양자화 조합은 R@5 하한이 −2.20으로 2%p 밖. 정적 구성(SPL)과의 조합은 아직 재지 않음

9. 실패·중단한 시도 (지우지 않고 보고)

시도	결과	배운 것
A2 정적 기본 + 회복 탐침 7종 + 캘리브 A/B 5종	전부 1.5~4.8%	범위 추정 방식이 아니라 Softmax·Add까지 양자화한 것이 원인 → A2m
Percentile 99.9 (A2m-pct)	14.90% 붕괴	이상치를 잘라내면 오히려 망가짐 (이상치가 의미 있는 값)
QOperator 형식	QDQ와 같은 정확도, 속도 이득 없음	QDQ 유지
가중치 INT4 (MatMulNBits)	63.94~66.93%, CPU 속도 이득 없음	fc2 보호로도 회복 안 됨 → 가중치 오차라는 다른 실패 양상. 기각
CIFAR 캘리브레이션	CIFAR 검증에서는 이득, COCO 검색에서 23.68%로 크게 악화	평가셋과 같은 도메인 효과였음 → COCO 캘리브 유지
Hailo a16_w8 (활성 16 / 가중치 8비트)	DFC 내부 오류	"원하는 설정 미지원"으로 분류
Hailo 이상치 64채널	컴파일러 내부 오류	재시도 안 함
텍스트 인코더 HEF (E17)	parse 성공, 공식 설정의 finetune이 CPU에서 WSL을 멈춤	공식 설정이 GPU 학습 전제(추정). 텍스트는 CPU 유지
밤 속도 측정 (10/14·15·16)	3회 모두 실행 안 됨	PC 절전으로 대기 작업이 깨어나지 못함 → 10/17 오전 즉시 실행으로 해결. Windows 절전 "안 함" 필요

10. 최종 구성과 최종 판정

	ORT (PC CPU)	Hailo-10H
최종 구성	**SPL-b567-k32**	**H-splf-b7-k32**
방식	정적 INT8 + 블록 5·6·7 fc2 입력 이상치 32채널만 FP32 작은 행렬곱으로 분리	공식 설정 + 블록 7 fc1+GELU+fc2의 이상치 32채널 갈래만 16비트(a16_w16)
공통 전략	**이상치 채널 격리:** 손실 원인인 소수 채널만 높은 정밀도로, 나머지는 8비트. "PC에서 찾은 전략을 그대로 NPU에 이식"	
동결	2026-10-17 15:22 (사용자 지시). 기준선 A0 / H-FP / H-official과 함께 한 번만 평가	

10-1. ORT 최종 판정 (완료, 10/17 15:24~15:45)

구성	confirm R@1	R@5	R@10	R@1 차이	CIFAR test	차이
A0 FP32	41.79%	68.09%	78.53%	—	68.01%	—
SPL-b567-k32	**40.84%**	**66.78%**	**77.91%**	**−0.95%p**	**68.66%**	**+0.65%p**

- select(−0.78)와 confirm(−0.95)의 차이가 작다 → **select에서 고른 결과가 새 데이터에서도 재현됨**
- confirm의 95% 신뢰구간과 마진 통과 여부는 작업 끝에 만들어지는 표(`results/coco_ret_confirm_final_ort.md`)로 확정
- CIFAR test +0.65%p는 표준오차(±0.47%p) 수준 → "손실 없음"으로 보고. FP32와 예측 일치율 86.86%, 평균 코사인 0.9739

10-2. Hailo 최종 판정 (진행 중)

구성	confirm R@1	R@5	R@10	CIFAR test
H-official	38.64%	64.84%	76.25%	진행 중
H-FP	진행 중			대기
H-splf-b7-k32	대기			대기

에뮬레이터가 CIFAR 1만 장을 세 구성으로 돌려야 해서 19시 전후 완료 예정. 작업: `jobs/20261017_1530_i_final_confirm_test.sh`, 평가 코드 `dfc/final_eval.py` (10/17 신규, select 평가와 같은 전처리·지표).

11. 남은 일과 일정 (마감 11/1 23:59)

#	할 일	상태 · 목표
1	Hailo 최종 판정 결과 정리 (confirm CI, CIFAR McNemar)	10/17 저녁
2	사진 색인 속도(사진/초, 1,000장 처리 시간, 메모리)와 검색 지연(질의 1개 p50·p95) 따로 측정	미착수
3	갤러리 데모 (select·confirm과 겹치지 않는 사진, 영어 검색어)	미착수
4	재현 패키지: README 재현 명령, requirements, 모델 파일 경로, 다른 PC 재현 검증	목표 10/27
5	데이터셋·모델 라이선스 기록	미착수
6	보고서 초안 → 제출	목표 10/31 → 11/1
7	Hailo 보드 실측 (추정 218 fps 확인). 담당자 미정	본선 전, 열린 질문
선택	H-splf-b7-k32 캘리브 seed s1·s2 재현성 / 정적 SPL + 해상도 192 조합	여유 있을 때

12. 보고서 작성 시 유의점

- Hailo fps는 **프로파일러 추정치**다 ("실측"이라고 쓰지 않는다). 보드 실측 전까지 컨텍스트 수와 함께 "추정"으로 표기

- ORT 개선량을 Hailo 개선량으로 옮겨 말하지 않는다. Hailo-8/8L 자료를 10H 근거로 쓰지 않는다
- 마진·선택 규칙을 select 결과와 속도 측정을 본 뒤 보완한 순서를 밝히고, 판정은 confirm 1회라는 점을 강조
- COCO 검색 수치는 자체 분할이라 공개 COCO 1K/5K 수치와 직접 비교하지 않는다
- 사실 / 가설 / 추측을 구분해서 쓴다 (예: E20 대리 지표의 일반화, E21 남은 0.6%p의 원인은 가설)
- 평가셋 크기(2,406장) 질문 대비: 학습용이 아니라 평가용이며, 판단은 이미지 단위 bootstrap CI로 하고 CI 반폭(약 ±1.4%p)을 근거로 마진을 정했다는 점을 설명
- 실패한 시도(9장)를 지우지 않고 근거로 쓴다: 무엇이 원인이 아닌지를 보여 주는 실험 설계 점수의 근거

부록. 구성 이름 읽는 법 · 주요 파일

이름	뜻
A0 / A1 / A2 / A2m	FP32 / 동적 INT8 / 정적 INT8 기본 / 정적, 가중치 MatMul 49개만
S-c67-fc2	정적 + 블록 6·7의 fc2(`mlp/c_proj`)를 FP32로 유지
-pc / -qop / -attn	채널별(per-channel) 가중치 눈금 / QOperator 형식 / 어텐션 MatMul까지 INT8
SPL-b567-k32	블록 5·6·7 fc2 입력의 이상치 32채널을 FP32 작은 행렬곱으로 분리
A1-c67-pc	동적 INT8 + fc2 b6·7 FP32 + per-channel
R192-···	입력 해상도 192
H-FP / H-official / H-fc2b7	Hailo 에뮬레이터 양자화 전 / 공식 설정 / 공식 + fc2 블록 7 층 전체 16비트
H-spl / H-splf	Hailo 이상치 채널 격리: fc2만 분할 / fc1+GELU+fc2 분할

파일	내용
`docs/00_새세션_시작안내.md`	읽는 순서, 폴더 지도
`docs/01_인수인계_현재상태.md`	현재 상태, 다음 할 일, 갱신 기록
`docs/02_실험기록_전체.md`	E01~E21 실험 노트
`docs/PROTOCOL.md`	측정·평가 규칙, 마진, 선택 규칙, 동결 기록
`docs/05_경량화전략_조사와계획.md`	경량화 기법 조사와 우선순위
`results/all_runs.md` , `results/coco_ret_*.md`	자동 생성 결과 표
`results/latency_20261017_morning.csv`	최종 속도 측정 원본
`dfc/split_hailo.py` , `src/split_outliers.py`	Hailo / ORT 이상치 채널 분리 코드
`D:\halio_data\hailo\*.hailo10h.hef`	컴파일된 HEF (splf_b7_k32 포함, 약 80 MB)