CLIP 양자화 × Hailo-10H 진행 정리

Oct 14, 2026 · @안세준

한눈에 보기

Hailo 기본 양자화는 사진 검색 정확도(R@1)를 2.95%p 떨어뜨렸고, 우리 방법(7번 블록 fc2만 16비트)은 그 손실을 0.48%p로 줄였어요.

- **목표:** 갤러리 사진을 기기 안에서 영어 문장으로 검색하고, 사진 색인(이미지 인코더)을 Hailo-10H로 가속한다.
- **지금 위치:** 후보 실험을 마치고 최종 후보를 고르는 단계예요. 다음은 ORT 속도 재측정, 그다음 최종 시험(COCO-confirm·CIFAR test)을 딱 한 번 열어요.
- **핵심 결론 3줄:**
  1. 정확도 손실의 원인은 6·7번 블록 fc2(MLP 축소층) 입력의 이상치 몇 채널이에요. CIFAR로 찾았고, COCO 검색에서도 똑같이 확인했어요.
  2. 그 층만 높은 정밀도로 남기면 ORT·Hailo 둘 다 FP32와 거의 같은 검색 품질이 나와요(2%p 기준 통과).
  3. 대가는 속도예요. Hailo 추정 속도가 221 → 170 fps(7번만) 또는 140 fps(6·7번)로 줄어요. 보드 실측으로 확인할 예정이에요.

지금까지 한 일

CIFAR로 원인을 찾고, 목표에 맞는 COCO 사진 검색 평가로 실제 효과를 확인했어요. 최신 순서예요.

날짜	한 일	결과
10/14	Hailo: 7번 블록 fc2만 16비트	R@1 −0.48%p, 14 컨텍스트, 추정 170 fps → Hailo 후보
10/14	비열등 마진·후보 선택 규칙 확정	마진 2%p (PROTOCOL.md)
10/14	HF 공식 CLIP과 정합성 확인	이미지·텍스트 코사인 1.000000, 통과
10/14	평가 사진으로 fc2 활성값 재측정	캘리브레이션 사진과 동일 → 이상치는 모델 고유 특성
10/13	Hailo COCO 검색 평가, 프로파일러	공식 −2.95, CIFAR 보정 −17.2, 6·7번 16비트 −0.80%p
10/13	ORT 9개 구성 COCO 검색 평가	A1-c67-pc −0.32%p가 최고

날짜	한 일	결과
10/13	COCO 분할 고정 (제외 189 / select 2,405 / confirm 2,406)	세 묶음 겹침 0, sha256 기록
10/13	정확도 개선 실험 (이상치 채널 분리, INT4, 동적+혼합)	CIFAR 후보 3개로 압축
10/7	Hailo에 6·7번 fc2 a16_w16 적용 (5,000장)	공식 −6.02 → −0.34%p (CIFAR)
10/7	fc2 입력 활성값 통계	7번 블록: 최대 42, INT8 255칸 중 9칸만 사용
10/6~7	층별 민감도 분석 (종류별 → 블록별)	손실 원인 = 6·7번 블록 fc2
10/6	작업 대기소(job queue) 구축	더블클릭 없이 실험 자동 실행
10/6 이전	모델 준비, ORT 파일럿(A0/A1/A2/A2m), Hailo 공식 컴파일	A2 붕괴, A2m CIFAR 손실 큼, Hailo 13 컨텍스트

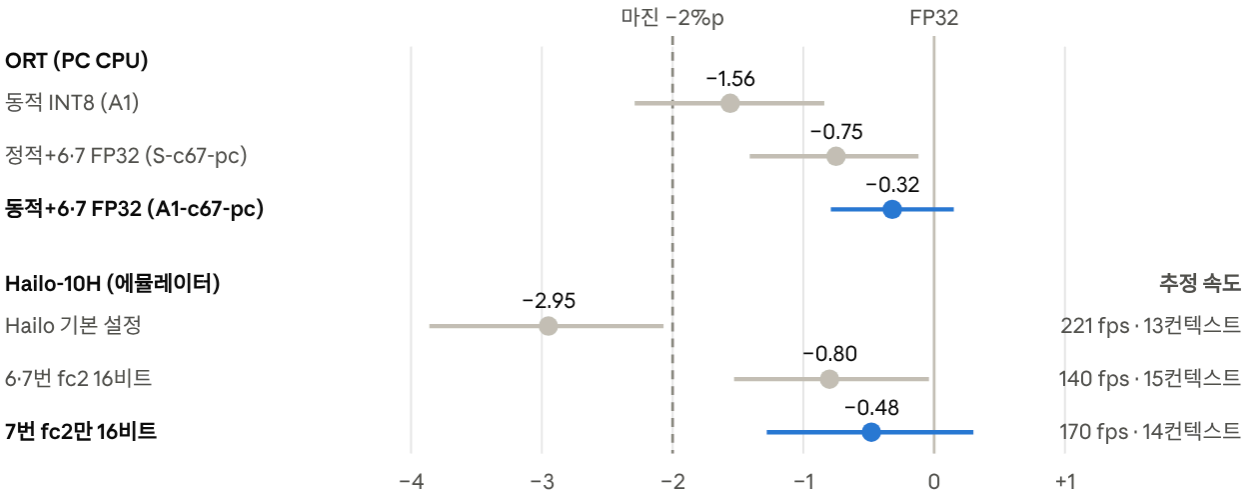
- A0 = FP32 원본, A1 = 동적 INT8, A2 = 정적 INT8(ORT 기본), A2m = 가중치 MatMul 49개만 정적 INT8
- "-c67" = 6·7번 fc2를 FP32로 남김, "-pc" = 채널별(per-channel) 가중치 양자화

핵심 결과

6·7번 블록 fc2를 높은 정밀도로 남긴 후보는 ORT·Hailo 모두 2%p 기준을 통과했고, 파란색이 규칙상 플랫폼별 후보예요. FP32 기준 R@1은 ORT·Hailo 모두 40.87%예요.

7번 블록 fc2만 16비트: Hailo 손실 −2.95 → −0.48%p, 2%p 기준 통과

COCO-select R@1, 같은 플랫폼 FP32 대비 차이(%p)와 95% 범위 (이미지 단위 bootstrap)



results/coco_ret_select.md, coco_ret_select_hailo.md · COCO-select 2,405장, 캡션 12,035개, bootstrap 2,000회 · fps는 DFC 프로파일러 추정치(실측 아님)

- 차트 밖의 구성: ORT 정적 INT8 기본(A2)은 R@1 0.15%로 붕괴, A2m은 −6.81%p, CIFAR 사진으로 보정한 Hailo는 −17.19%p예요. S-c67-fc2(−1.55), SPL-b567-k32(−0.78), S-c67-pc-attn(−1.63)은 표 파일에 있어요.
- Hailo 7번만 16비트는 R@1은 가장 좋지만 R@5·R@10 손실(−1.85, −1.73%p)은 6·7번 16비트(−1.45, −0.89%p)보다 커요.
- 우리 모델과 HF 공식 CLIP의 임베딩 코사인은 1.000000이고, Hailo FP 에뮬레이터도 ORT FP32와 코사인 1.00000이에요.

팀이 확정한 규칙

"FP32와 거의 같다"의 기준은 2%p로 정했고, 최종 판정은 아직 아무도 안 본 COCO-confirm으로 딱 한 번 해요. 전문은 `docs/PROTOCOL.md`에 있어요.

1. **마진 2%p:** COCO-select R@1 차이의 95% 범위 하한이 −2.0%p 이상이면 통과. 기준은 같은 플랫폼의 FP32(ORT는 A0, Hailo는 H-FP)예요.
   - 근거: 갤러리 약 2,400장에서는 측정 오차가 약 ±1.4%p라 1%p 기준은 판별이 어려워요.
   - 투명성: select 결과를 본 뒤 정했다는 점을 보고서에 밝혀요.
2. **후보 선택 순서:** 마진 통과 → 그중 빠른 것 → 같으면 R@1 높은 것. 플랫폼별 1개, 합계 3개 이하.
3. **최종 시험은 한 번만:** COCO-confirm과 CIFAR test는 후보를 정한 뒤 한 번만 열고, 결과가 나빠도 후보를 바꾸지 않아요.
4. **분할 고정:** 제외 189장 / select 2,405장 / confirm 2,406장을 첫 평가 전에 파일로 고정했고, 세 묶음이 겹치지 않음을 로그로 남겼어요.
5. **캘리브레이션 사진:** 제외 목록이나 COCO train2017에서만 뽑아요. 코드가 평가 사진과 겹치는 목록을 자동으로 거부해요. Hailo에 실제로 넣은 64장도 DFC 로그로 확인했고, 전부 제외 목록 안이에요.
6. **데모 사진:** select·confirm과 겹치지 않게 골라요.

남은 일

예선 제출은 Nov 1, 2026 23:59이에요. 아래 순서대로 진행해요.

- [ ] ORT 후보 속도 재측정: PC에서 다른 작업이 없을 때만, 약 30분
- [ ] 플랫폼별 최종 후보 확정: ORT는 A1-c67-pc가 유력, Hailo는 7번만 16비트
- [ ] 최종 시험 1회: COCO-confirm(후보 + A0·H-FP·H-official)과 CIFAR test
- [ ] 사진 색인 속도(사진/초, 1,000장 시간, 메모리)와 검색 지연(p50/p95)을 따로 측정
- [ ] Hailo 보드 실측: 프로파일러 추정치(221/170/140 fps)를 실측으로 확인
- [ ] 갤러리 데모: select·confirm과 겹치지 않는 사진, 영어 검색어
- [ ] 재현 패키지와 보고서 작성

열린 질문: Hailo 보드 실측은 누가, 언제 할지 정해야 해요.

보고서에서 피할 표현

수치를 과장하거나 잘못 읽힐 수 있는 표현은 쓰지 않아요.

피할 표현	대신 쓸 표현
"FP32를 넘었다", "102%"	"FP32와 차이 X%p [95% 범위]"
"갤러리 검색이 빨라졌다"	"사진 색인이 빨라졌다" (가속한 건 이미지 인코더)
"한국어 갤러리 검색"	"영어 문장 검색"
ORT에서 얻은 개선을 Hailo 개선처럼 서술	플랫폼별로 따로 보고
프로파일러 fps를 실측처럼 서술	"프로파일러 추정치(실측 아님)"
공개 COCO 1K/5K 수치와 직접 비교	"자체 COCO val2017 분할(갤러리 약 2,400장)"
"Hailo보다 낫다", "Hailo 공식 수치와 같은 평가셋"	"같은 평가에서 Hailo 기본 설정 대비"
"A2 붕괴는 확실히 재현된다"	"우리 설정에서 관찰했다"

- CIFAR 사진으로 보정한 Hailo 모델은 CIFAR 정확도는 올랐지만 실제 사진 검색에서 무너졌어요 (R@1 23.7%). CIFAR에서의 향상을 성과로 쓰지 않아요.
- 마진을 select 결과를 본 뒤 정했다는 점을 숨기지 않아요.